

Рекомендательная система для главной страницы интернет-магазина

Постановка задачи

- ▶ **Проблема:** на главной странице 3 слота под рекомендации — нужно показать самые релевантные товары каждому пользователю.
- ▶ **Бизнес-метрика:** рост прибыли от допродаж на **20%**
- ▶ **Техническая метрика: Precision@3** — доля пользователей, у которых купленный товар попал в топ-3 рекомендаций
- ▶ **Как измеряем:**
 - ▶ Для каждого пользователя с покупкой формируем 100 кандидатов (1 купленный + 99 негативов)
 - ▶ Модель ранжирует, берём топ-3
 - ▶ $\text{Precision@3} = \text{доля попаданий}$
 - ▶ Случайный уровень = 0.03

Данные

▶ Три таблицы:


Таблица	Что содержит	Объём
events	События: просмотр, корзина, покупка	2.75 млн строк
item_properties	Свойства товаров (категория, захешированные признаки)	20 млн строк
category_tree	Иерархия категорий	1 669 узлов

▶ Ключевые характеристики:

- ▶ 1.4 млн пользователей, 235 тыс. товаров
- ▶ Сильный дисбаланс: 96.7% просмотров, 0.8% покупок
- ▶ **87% пользователей имеют <10 событий** — массовый холодный старт
- ▶ **Разделение по времени:** train (до 17.08), val (18–31.08), test (01–17.09)

Архитектура модели

- ▶ Гибридная архитектура: Retrieval + Ranking
- ▶ Для каждого пользователя: из 100 кандидатов отбираем 20 самых популярных, затем CatBoost ранжирует их по вероятности покупки и выбирает 3 для показа



Работа модели

- ▶ Для каждого пользователя мы заранее сформировали **пул из 100 товаров** (1 реально купленный товар + 99 смотрел, но не купил)
- ▶ **Шаг 1. Retrieval — из 100 в 20**
 - ▶ В отбираем 20 самых популярных по признаку `item_daily_addtocart_last_7d` (сколько раз товар добавляли в корзину за последние 7 дней)
 - ▶ Это **необучаемое правило** — просто сортировка.
 - ▶ Цель: быстро отсеять «мусор» (непопулярные товары) и оставить только релевантных кандидатов
- ▶ **Шаг 2. Ranking — из 20 в топ-3**
 - ▶ **20 товаров** идут в **CatBoost**. Модель для каждого из 20 товаров предсказывает вероятность покупки, используя **все признаки** (категорию, историю пользователя, контекст сессии и т.д.)
 - ▶ Сортируем 20 товаров по предсказанной вероятности
 - ▶ Берём **топ-3** — это и есть финальные рекомендации, которые показываются пользователю.

Основные признаки модели

Стратегия	Признак	Для кого
Популярность категории	Популярность товара по корзинам за 7 дней	Все, особенно холодные
	Категория товара	Все, особенно холодные
	Родительская категория	Все, особенно холодные
	Корзины за 30 дней	Все, особенно холодные
	Просмотры категории за 7 дней	Все, особенно холодные
	Просмотры категории за 30 дней	Все, особенно холодные
Контекст момента	Время с начала сессии	Все
	Номер события в сессии	Все
	День недели	Все
	Время суток	Все
Тренд	Рост интереса к товару	Все, ловит новинки

Результаты экспериментов

- ▶ Доля пользователей, у которых купленный товар попал в топ-3 рекомендаций на тестовой выборке

Модель	Precision@3
Случайный выбор	0.030
Бейзлайн популярности	0.507
CatBoost (Optuna)	0.507
Гибрид (финальная модель)	0.645

Итоги

- ▶ **Итог:** Доля пользователей, у которых купленный товар попал в топ-3 рекомендаций = **0.645**
 - ▶ в 21 раз лучше случайного уровня
 - ▶ +14 п.п. к бейзлайну и чистому CatBoost
- ▶ **Что это значит для бизнеса:**
 - ▶ В 65% случаев пользователь видит купленный товар в топ-3
 - ▶ Модель работает и для холодных пользователей (за счёт популярности и контекста)
 - ▶ Для оценки роста прибыли после применения модели нужно провести A/B-тест